PROYECTO RAG

ALUMNOS: Anghie Chilon (DNI 72675195)
Carlos Mendoza (DNI 10060561)

Situación problemática

En una institución educativa, para la escuela de Estadística, los estudiantes del curso de Machine Learning tienen acceso a una gran cantidad de recursos, incluyendo libros, PDFs, artículos académicos y manuales técnicos. Sin embargo, cuando necesitan resolver dudas concretas por ejemplo, “¿Qué es overfitting?” o “¿Cómo funciona un árbol de decisión?” se enfrentan a la dificultad de buscar manualmente entre cientos de páginas de libros o en paginas web, esto consume mucho tiempo y puede generar frustración.

Esta situación se agrava cuando la información está dispersa o redactada de manera compleja, dificultando la comprensión rápida. Además, la mayoría de bibliografía con buenas referencia se encuentra en otro idioma.

Arquitectura

https://github.com/AnghieLizzeth22/IA_GEN_PROYECTO_RAG_ML.git

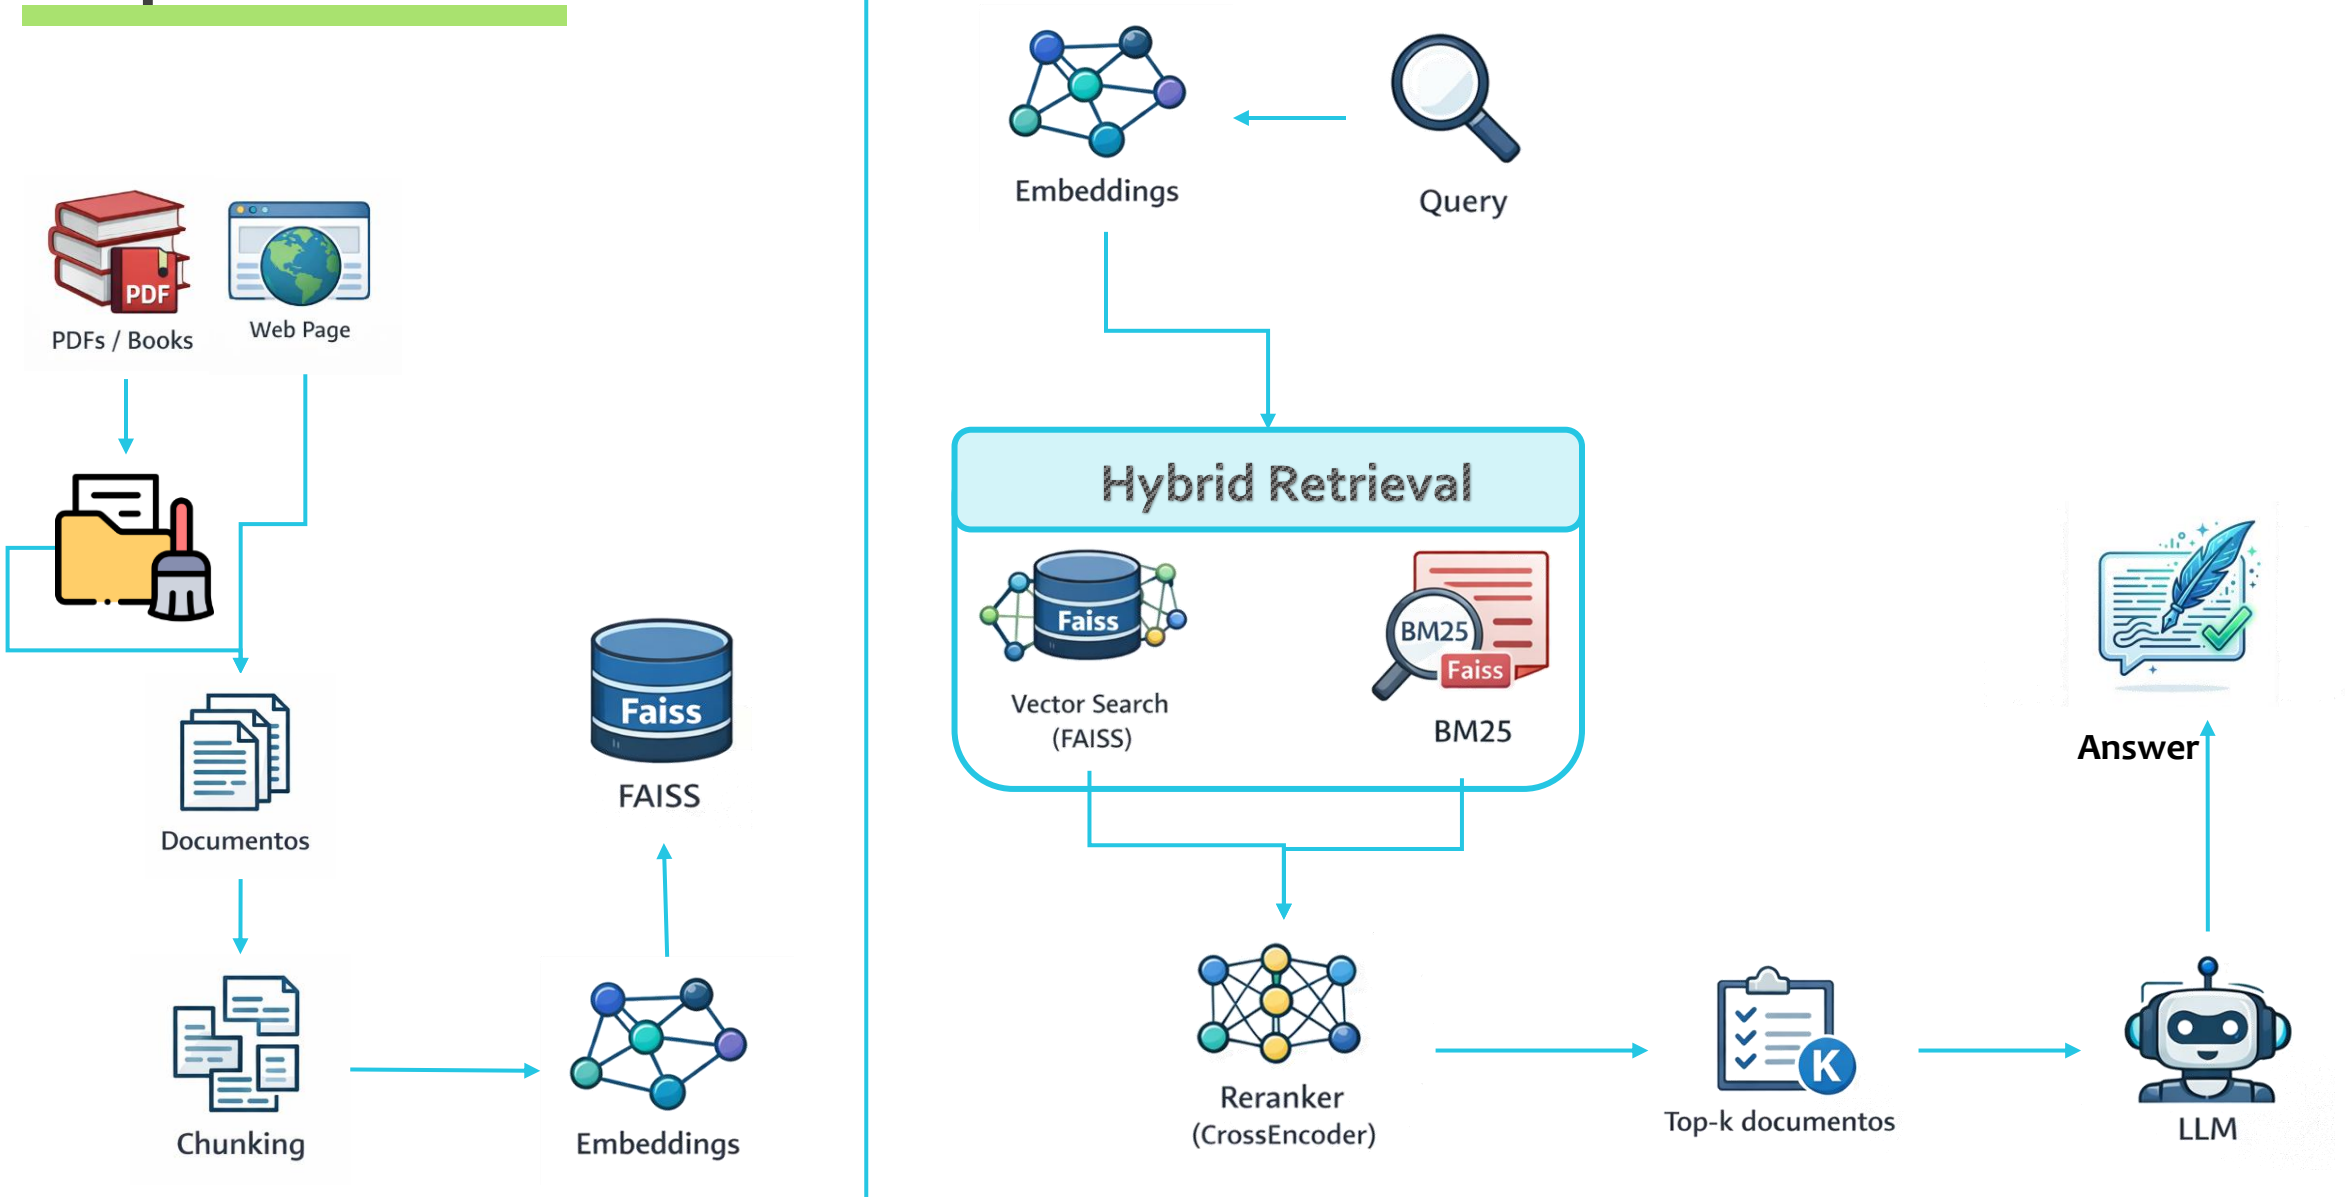

Decisiones Técnicas

Chunks	Los documentos se dividieron en chunks de aproximadamente 700 tokens, lo que permite mantener suficiente contexto semántico sin afectar la precisión en la recuperación.
Embedding	Se utilizó el modelo all-MiniLM-L6-v2 de Sentence-Transformers, ya que es un modelo ligero ligero optimizado para semantic search y retrieval
Hybrid Retrieval (BM25 + FAISS)	Combina búsqueda semántica con coincidencia de palabras clave para mejorar la recuperación de documentos
Top K documentos y Compression de contexto	Se selecciona un número limitado de documentos relevantes y además se elige los párrafos más relevantes dentro de cada documento usando similitud semántica

Decisiones Técnicas

Modelo Llama2

Se utilizó el modelo Llama 2 para generar las respuestas, ya que es un modelo abierto que permite integrarse fácilmente en sistemas RAG y generar texto coherente utilizando el contexto recuperado.

DEMO

Resultados

```
questions = [
    "¿Qué es overfitting?",
    "¿Qué es el aprendizaje supervisado?",
    "¿Qué es el aprendizaje no supervisado?",
    "¿Qué es la regresión lineal?",
    "¿Qué es un árbol de decisión?",
    "¿Qué es el descenso por gradiente?"
]
```

Evaluación
BLEU / ROUGE / Grounding

```
references = {

"¿Qué es overfitting?":
"El overfitting ocurre cuando un modelo se ajusta demasiado a los datos de entrenamiento y no generaliza bien a nuevos datos. Esto sucede cuando el modelo aprende patrones específicos del entrenamiento en lugar de relaciones generales.",

"¿Qué es el aprendizaje supervisado?":
"El aprendizaje supervisado es una técnica de machine learning que utiliza datos etiquetados para entrenar modelos. El objetivo es aprender patrones que permitan predecir resultados en nuevos datos.",

"¿Qué es el aprendizaje no supervisado?":
"El aprendizaje no supervisado utiliza datos no etiquetados para descubrir patrones o relaciones en los datos. El modelo aprende estructuras ocultas sin conocer previamente las respuestas correctas.",

"¿Qué es la regresión lineal?":
"La regresión lineal es un método que modela la relación entre una variable dependiente y una o más variables independientes. Se utiliza para realizar predicciones sobre valores continuos.",

"¿Qué es un árbol de decisión?":
"Un árbol de decisión es un modelo predictivo que utiliza una estructura de árbol para tomar decisiones. Cada nodo representa una condición sobre los datos y las ramas conducen a diferentes resultados.",

"¿Qué es el descenso por gradiente?":
"El descenso por gradiente es un algoritmo de optimización utilizado para minimizar una función de pérdida. Ajusta iterativamente los parámetros del modelo en la dirección que reduce el error."
}
```

Resultados

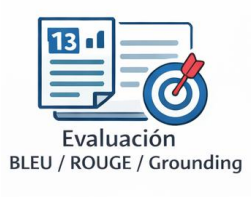


```
Pregunta: ¿Qué es la regresión lineal?
Both `max_new_tokens` (=200) and `max_length`(=4096) seem to have been set. `max_new_tokens` will take precedence. Please refer to the documentation for mo

Respuesta:
La regresión lineal es una técnica de aprendizaje automático utilizada para identificar la relación
entre una variable dependiente continua y una o más variables independientes. La regresión lineal se
utiliza para hacer predicciones sobre resultados futuros y se expresa a través de una línea recta.

Citation per sentence:
- La regresión lineal es una técnica de aprendizaje automático utilizada para identificar la relación
entre una variable dependiente continua y una o más variables independientes. [1 | sim=0.72 | https://www.ibm.com/es-es/think/topics/supervised-learning]
- La regresión lineal se utiliza para hacer predicciones sobre resultados futuros y se expresa a
través de una línea recta. [1 | sim=0.77 | https://www.ibm.com/es-es/think/topics/supervised-learning]

Fuentes:
[1] https://www.ibm.com/es-es/think/topics/supervised-learning
[2] https://www.ibm.com/es-es/think/topics/supervised-learning
[3] https://www.ibm.com/es-es/think/topics/supervised-learning
[4] https://www.ibm.com/es-es/think/topics/supervised-learning
[5] https://www.ibm.com/es-es/think/topics/deep-learning

ROUGE-L: 0.565
BLEU: 0.277
Grounding: 0.842
```

Resultados

```
==================================
RESULTADOS PROMEDIO
ROUGE promedio: 0.35
BLEU promedio: 0.15
Grounding promedio: 0.79
```

Problemas

- Recuperación de documentos no siempre relevante → **Hybrid Retrieval**
- Pérdida de contexto al dividir documentos → **Chunk overlap**
- Demasiado contexto para el LLM → **Top K y compression context**
- Costo computacional del reranker

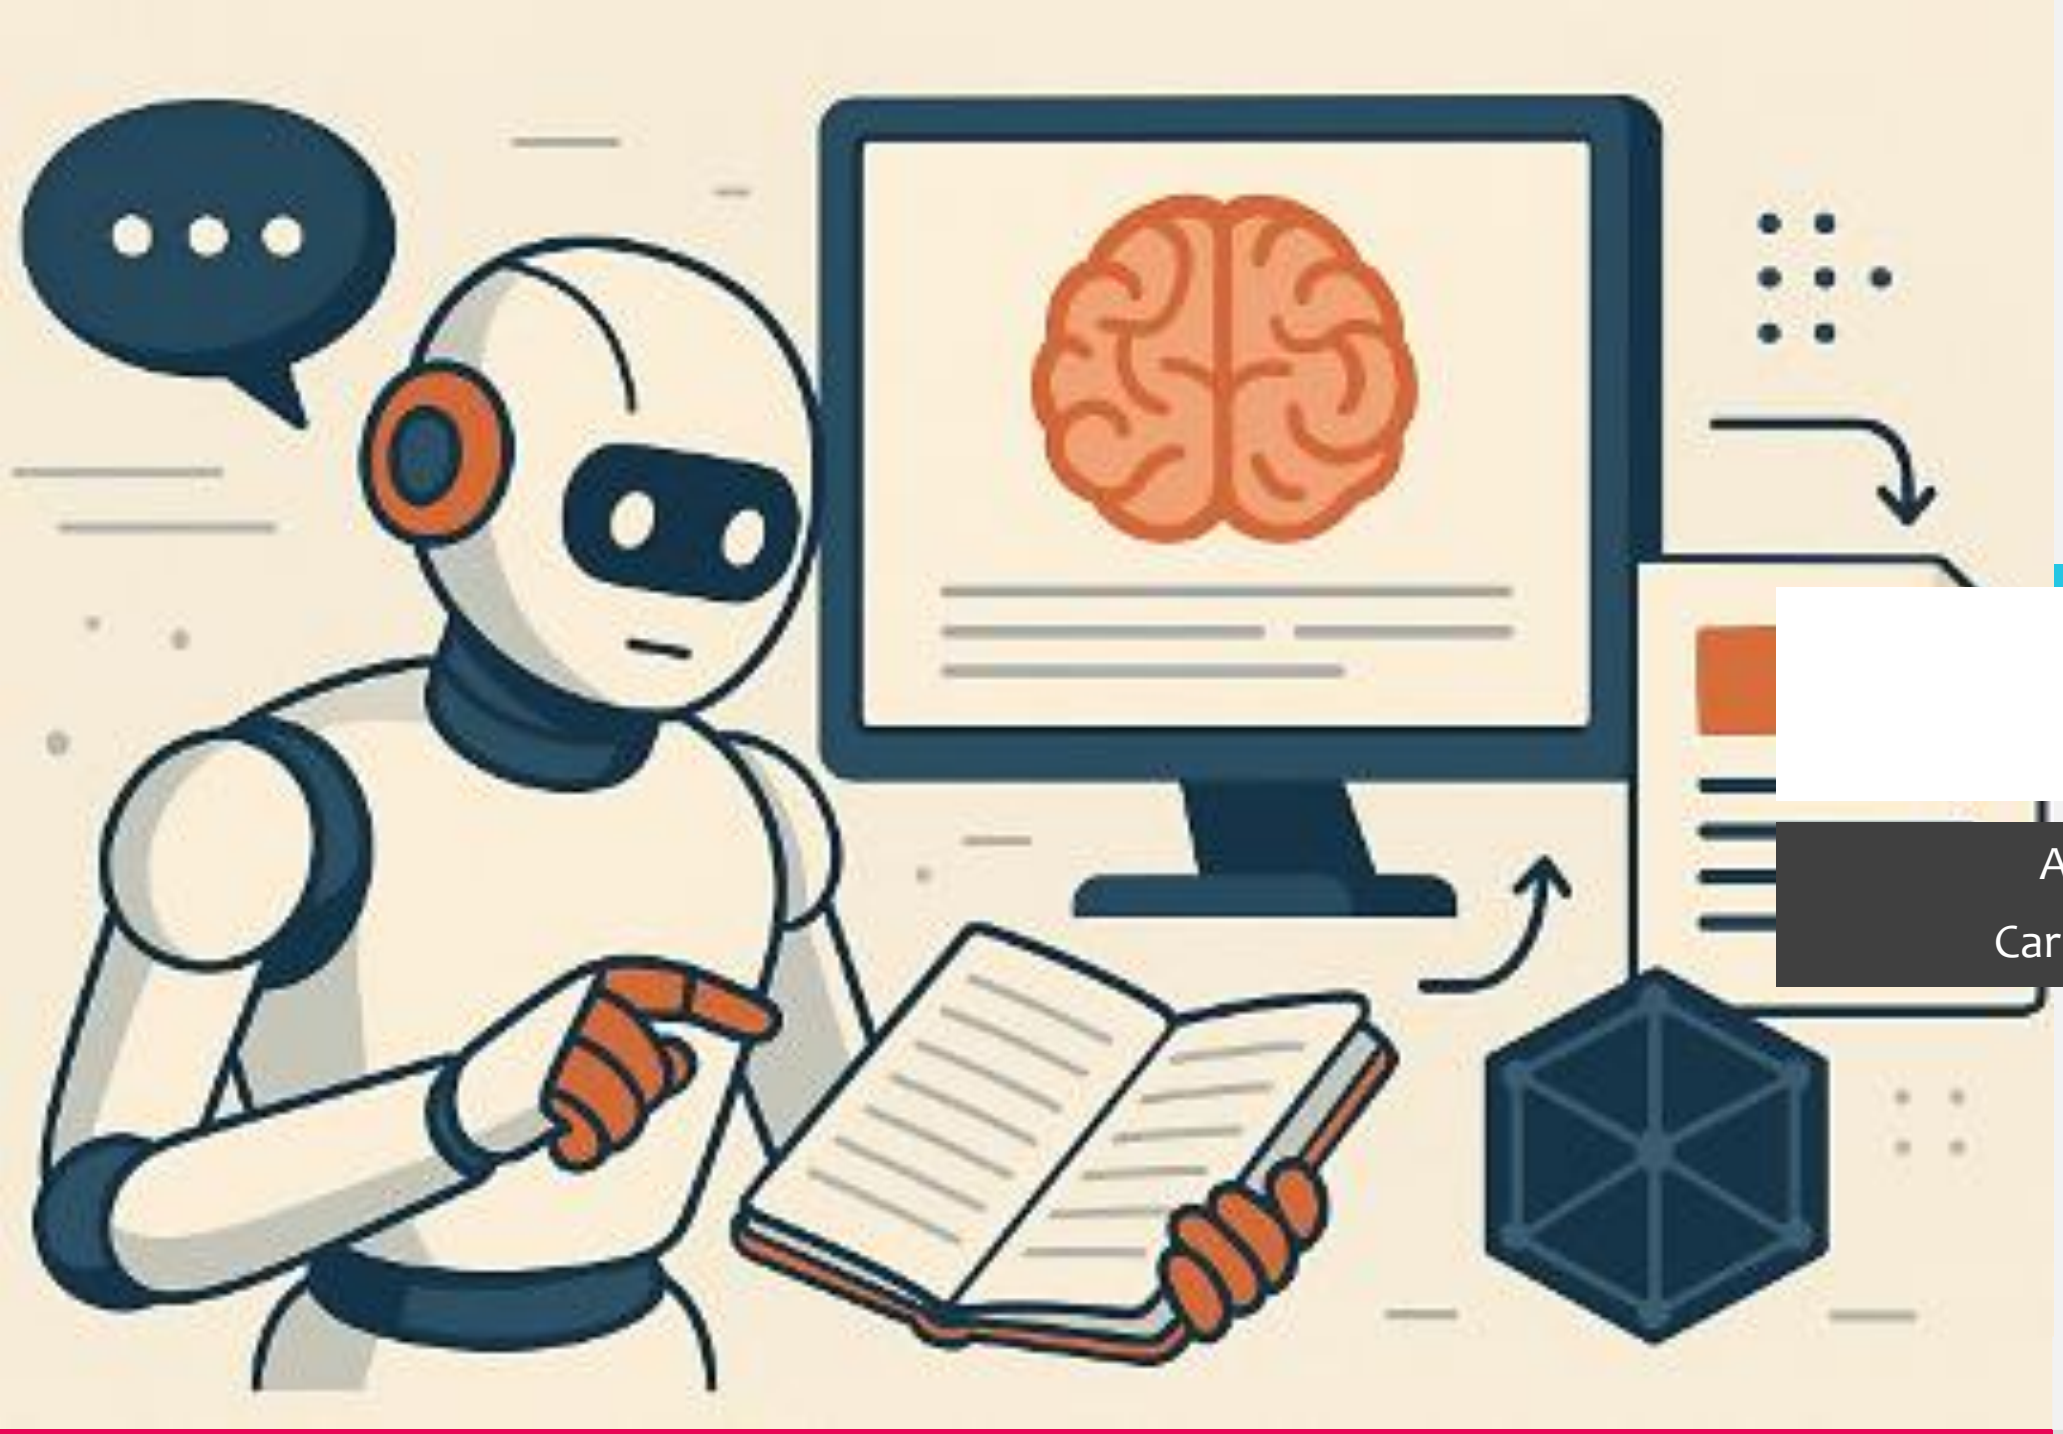

Gracias

Anghie Chilon
Carlos Mendoza